

# Econometrics Note 1

2024年7月11日 14:54

L<sub>1</sub>

1) Formal Econometric model

需求的经济模型：

$$\text{quantity} = f(\text{price}, \text{income})$$

计量模型：

$$\text{quantity}_t = \beta_0 + \beta_1 \text{price}_t + \beta_2 \text{income}_t + u_t$$

未知参数 ↗ 误差项(无明显关系的其它项)

2) Hypothesis

e.g. Returns to Education

$$\text{wages}_i = \beta_0 + \beta_1 \text{educ}_i + \beta_2 \text{IQ}_i + u_i$$

to: educ 与 wages 无关:  $\beta_1 = 0$

IQ 对 wage 有正的影响:  $\beta_2 > 0$

L<sub>2</sub> 一元线性回归

$$1) y_i = \beta_0 + \beta_1 x_i + u_i$$

$i=1, \dots, n$ : 每一个  $(y_i, x_i)$  与其它的相互独立

$\beta_1$ : slope parameter;  $\beta_0$ : intercept parameter

Assume: on average the error term is zero:  $E(u_i) = 0$

(意为  $u$  与  $x$  之间无任何关系)(误差项不会对函数造成影响)

$$0 \Delta y = \beta_1 \Delta x \quad \text{if } \Delta u = 0$$

- 但 ① 成立,  $E(u_i) = 0$

$$\cdot \text{more importantly, } E(u_i | x_i) = 0$$

2) OLS Estimator


$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}; \quad \hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\text{Cov}(x, y)}{\text{Var}(x)}$$

fitted values from LR (线性回归)

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

residuals (残差)

$$\hat{u}_i = y_i - \hat{y}_i \\ = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)$$



3) Gauss-Markov Assumption (高斯-马尔科夫假设)

SLR. 1 (模型的变量是线性的)

$$y = \beta_0 + \beta_1 x + u$$

SLR. 2 (自变量为随机数据)

$$(x_i, y_i); i=1, \dots, n$$

SLR. 3 (解释变量有样本差异) (解释变量间无完全共线性)

SLR. 4 (零均值) (ZCM)

$$E(u_i | x_i) = 0 \rightarrow E(y|x) = \beta_0 + \beta_1 x$$

Population Regression Function (PRF) (总体回归函数)

· 反映  $y$  的均值随  $x$  的变化, 非在所有单位下  $y$  等于  $\beta_0 + \beta_1 x$   
(for all units in the population)

(是线性的意味着  $x$  改变一个单位,  $y$  的期望值更变  $\beta_1$ )

SLR. 5 (误差项  $u$  与其它任何  $x$  的值有相同的方差)

4) Unbiasedness of OLS (无偏性)

·  $\hat{\beta}_1$  is estimated from data

( $\hat{\beta}_1$  是对数据的一个预测; 不同数据有不同的  $\hat{\beta}_1$ )

·  $\hat{\beta}_1$  is a random variable

( $\hat{\beta}_1$  是随机变量; 它是随机误差项的函数)

$$E[\hat{\beta}_1] = \beta_1?$$

用预测的  $\hat{\beta}_1$  所求的期望

(OLS 估计量的线性性)

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$= \frac{\sum_{i=1}^n y_i(x_i - \bar{x}) - \bar{y} \sum_{i=1}^n (x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$= \frac{\sum_{i=1}^n y_i(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$= \sum \left[ \frac{x_i - \bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2} \right] y_i$$

$$\text{令 } \lambda_i = \frac{x_i - \bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\therefore \hat{\beta}_1 = \sum \lambda_i y_i$$

·  $\hat{\beta}_1$  是解释变量  $y_i$  的线性组合

$$\sum_{i=1}^n \lambda_i = \frac{\sum_{i=1}^n (x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} = 0$$

$$\sum_{i=1}^n \lambda_i (x_i - \bar{x}) = \sum_{i=1}^n \lambda_i (x_i - \bar{x}) \sum_{i=1}^n \lambda_i = \sum_{i=1}^n \lambda_i x_i = 1$$

$$\sum_{i=1}^n \lambda_i^2 = \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{(\sum_{i=1}^n (x_i - \bar{x})^2)^2} = \frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

( $\beta_i$  是随机变量；它是随机误差项的函数)

$$E[\hat{\beta}_i] = \beta_i ?$$

用预测的  $\hat{\beta}_i$  所求的期望

### 5) OLS estimator

如果均符合高斯-马尔科夫假设 (SLR.1 - SLR.4), 则 OLS 预测量为自变量系数的无偏估计量)

$$E(\hat{\beta}_0) = \beta_0$$

$$E(\hat{\beta}_1) = \beta_1$$

Assume Homoskedasticity (同方差性)

· SLR.5  $u$  和其它  $X$  有相同的方差

$$\text{Var}(u|x) = \sigma^2$$

(SLR.1 ~ SLR.5)

$$\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sigma^2}{SST_x}$$

e.g.  $y = \beta_0 + \beta_1 x + u$  ( $x_i \sim N$  的数减  $x$  的平均值) ( $y_i \sim N$  的数减  $y$  的平均值)

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} ; \hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\text{Cov}(x, y)}{\text{Var}(x)}$$

(  $x_i \sim N$  的数减  $x$  的平均值的平方)

Fitted model:  $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$  (OLS regression line / Sample regression function)

Interpretation:  $\Delta \hat{y} = \hat{\beta}_1 \Delta x$

$$\text{Residuals: } \hat{u}_i = y_i - \hat{y}_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)$$

Properties:

Sample counterparts

$$\frac{1}{n} \sum_{i=1}^n \hat{u}_i = 0 \quad (\text{误差平均值为 } 0; E(u) = 0)$$

$$\frac{1}{n} \sum_{i=1}^n x_i \hat{u}_i = 0 \quad (\text{零均值}; E(u|x) = 0)$$

OLS 将  $y$  分解为拟合值和残差:

$$SST = SSE + SSR$$

Total Sum of Squares (SST) (总偏差平方和 (反映全部数据误差大小的平方和))

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2$$

Explained Sum of Squares (SSE) (回归平方和 (因变量回归值与因变量平均值  $\bar{y}$  的离差平方和))

$$SSE = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

Residual Sum of Squares (残差平方和 (衡量变量拟合程度))

$$SSR = \sum_{i=1}^n \hat{u}_i^2$$

(如果预测结果相近, SSE 与 SST 几乎相同)

### 6) 拟合程度 (Coefficient of determination / R-squared)

$$R^2 \equiv \frac{SSE}{SST} = 1 - \frac{SSR}{SST}$$

$$\frac{SST - SSR}{SST}$$

(拟合后,  $SST \Rightarrow SSE, SSR \Rightarrow 0$ , 所以  $R^2 \Rightarrow 1$ )

### 7) OLS 中用虚拟变量 (dummy variable)

(虚拟变量 0 或 1 代表可量化的观测值)

$$y_i = \beta_0 + \beta_1 x_i + u_i \quad (\checkmark, x=1; x=0)$$

Interpretation:

$$\hat{\beta}_1 = E(y_i | x_i = 1) - E(y_i | x_i = 0)$$

(OLS 估计量的无偏性)

$$\begin{aligned} \hat{\beta}_1 &= \sum_{i=1}^n \lambda_i (\beta_0 + \beta_1 x_i + u_i) \\ &= \beta_0 \sum_{i=1}^n \lambda_i + \beta_1 \sum_{i=1}^n \lambda_i x_i + \sum_{i=1}^n \lambda_i u_i \\ &= \beta_1 + \sum_{i=1}^n \lambda_i u_i \end{aligned}$$

$$\begin{aligned} E(\hat{\beta}_1) &= E(\beta_1 + \sum_{i=1}^n \lambda_i u_i) \\ &= \beta_1 + \sum_{i=1}^n \lambda_i E(u_i) \\ &= \beta_1 + 0 \\ &= \beta_1 \end{aligned}$$

$$y_i = \beta_0 + \beta_1 x_i + u_i \quad (\checkmark, x=1; x=0)$$

Interpretation:

$$\hat{\beta}_1 = E(y_i | x_i = 1) - E(y_i | x_i = 0)$$

### 8) 回归计算中用对数 (logarithms)

(当变量中有大量差异时使用)

$$\log(y_i) = \beta_0 + \beta_1 x_i + u_i$$

TABLE 2.3 Summary of Functional Forms Involving Logarithms

Model	Dependent Variable	Independent Variable	Interpretation of $\beta_1$
Level-level	y	x	$\Delta y = \beta_1 \Delta x$
Level-log	y	$\log(x)$	$\Delta y = (\beta_1 / 100\%) \Delta x$
Log-level	$\log(y)$	x	$\% \Delta y = (100\beta_1) \Delta x$
Log-log	$\log(y)$	$\log(x)$	$\% \Delta y = \beta_1 \% \Delta x$

### L3 多元线性回归

$$1) y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + u_i$$

(从  $i=1 \sim n$ , 每个观测值  $(y_i, x_{i1}, \dots, x_{ik})$  独立)

依旧假设: 1.  $E(u_i) = 0$

$$2. E(u_i | x_{i1}, \dots, x_{ik}) = 0$$

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2}$$

$\hat{\beta}_0$ , 当  $x_1 = x_2 = 0$  时 y 的预测值

$\hat{\beta}_1$ ,  $x_1$  对 y 的部分影响 (partial effect), 是  $x_1$  的条件影响

( $x_1$  对 y 的影响是在  $x_2$  不变下, ceteris paribus effect)

$\hat{\beta}_2$ ,  $x_2$  对 y 的部分影响 (partial effect)

### 2) 多元回归下的 OLS 预测值

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2}$$

当  $\hat{u}_i$  是估计残差时,  $x_1$  与  $x_2$  之间无任何影响 ( $x_1$  无法解释  $x_2$ )

$$x_{i1} = \hat{\alpha}_0 + \hat{\alpha}_1 x_{i2} + \hat{r}_{i1}$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n \hat{r}_{i1} y_i}{\sum_{i=1}^n \hat{r}_{i1}^2}$$

(当  $x_1, x_2$  和  $y$  不变下的  $\hat{\beta}_1$ )

### 3) 矩阵中的 OLS 预测值

$$\hat{Y} = X \hat{\beta} + u$$

$$\hat{\beta} = (X'X)^{-1} X' y$$

### 4) 高斯马尔科夫假设

MRL.1 总体模型是线性的

$$Y = X \beta + u$$

MRL.2 数据是总体中的随机值 ( $y_i, x_{i1}, \dots, x_{ik}$ )

MRL.3  $X$  无关线性

MRL.4 Zero Condition Mean (ZCM)

$$E(u | x_1, x_2, \dots, x_k) = 0$$

从 MRL.1 ~ 4 得出:  $E(\hat{\beta}) = \beta$

MRL.5 Homoskedasticity ( $u$  和其它任意 ( $x_1, x_2, \dots, x_k$ ) 有相同方差)

$$\text{Var}(u | x_1, x_2, \dots, x_k) = \sigma^2$$

### 5) Variance of OLS estimator

$$\text{Var}(\hat{\beta} | X) = \sigma^2 (X'X)^{-1}$$

$$\left\{ \begin{array}{l} \hat{\beta} = (X'X)^{-1} X' y \\ \text{(看作为矩阵系数)} \\ \text{则 } \hat{\beta} \text{ 与 } y \text{ 为线性组合} \end{array} \right.$$

$$\left\{ \begin{array}{l} \text{(OLS 估计量的无偏性)} \\ \hat{\beta} = (X'X)^{-1} X' y = (X'X)^{-1} X' (X\beta + u) \\ = (X'X)^{-1} X' X \beta + (X'X)^{-1} X' u \\ = \beta + (X'X)^{-1} X' u \\ E(\hat{\beta} | X) = E[\beta + (X'X)^{-1} X' u | X] \\ = \beta + (X'X)^{-1} X' E(u | X) \\ = \beta + 0 \\ = \beta \\ E(\hat{\beta}) = E_x E(\hat{\beta} | X) = E_x(\beta) = \beta \end{array} \right.$$

6) Estimating the Standard Error of the regression

$$\sigma^2 = E[u^2]$$

(不观测  $u$ )

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{u}_i^2}{n-k-1} = \frac{SSR}{n-k-1}$$

(自由度,  $n$ =观测数量,  $k+1$  是预测变量)  
(!!! 自由度有时为  $n-k$ , 取决于  $k$  的定义)

7) ZCM

$$E[u|x_1, x_2, \dots, x_k] = 0$$

当满足ZCM时, 我们说我们有 exogenous explanatory variables

如果:

$$E[u|x_j] \neq 0$$

我们说  $x_j$  是 endogenous explanatory variable

(这是因果推断的关键, 如有 omitted variables 则易被违反)

8) 矩阵

$$y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + u_i$$

(有  $N$  个关于变量的观测值)

$$y = X\beta + \epsilon$$

( $y$  是  $N \times 1$ ,  $\beta$  是  $(p+1) \times 1$  变量的向量,  $X$  是  $N \times (p+1)$  观测值

的矩阵,  $\epsilon$  是  $N \times 1$  误差的矩阵)

9) 假设:

$$E(\epsilon) = 0_N$$

$$E(\epsilon \epsilon') = \sigma^2 I_N$$

$X$  is fixed in repeated samples

$X$  has rank less than  $N$

(所以我们假设误差项的期望为 0, 同方差,  $X$  不变, 观测值比变量多)

10) 向量  $\beta$ ,  $\hat{\beta} = [\hat{\beta}_0, \dots, \hat{\beta}_p]$

a residual column vector of  $e$ :

$$(残差向量) \quad e = y - X\hat{\beta}$$

(矩阵  $X$ ) (向量  $\beta$  的预测值)

(再将 各残差的平方和最小化, 便可定义为数字  $e'e$  (维数为  $1 \times 1$  矩阵))

如下:

$$\begin{aligned} (\text{表示是 } e \text{ 的}) \quad e'e &= (y - X\hat{\beta})'(y - X\hat{\beta}) \\ (\text{整理}) \quad &= (y' - \hat{\beta}'X')(y - X\hat{\beta}) \\ &= y'y - \hat{\beta}'x'y - y'X\hat{\beta} + \hat{\beta}'X'X\hat{\beta} \end{aligned}$$

(化简)

(皆可转置)  $\hat{\beta}'X'y = y'X\hat{\beta}$

$$\therefore e'e = y'y - \hat{\beta}'X'y - \hat{\beta}'X'X\hat{\beta} + \hat{\beta}'X'X\hat{\beta}$$

$e'e = y'y - 2\hat{\beta}'X'y + \hat{\beta}'X'X\hat{\beta}$  ← (我们所需最小化的关于变量的矩阵的表达式)

(再找其最小)

$$\left( \begin{array}{l} \text{(矩阵求导法则)} \\ \text{如果 } f(x) = a'X : a \text{ 是 } x \text{ 的向量} \\ \frac{\partial f(x)}{\partial a} = X \\ \text{如果 } f(x) = a'Xa : X \text{ 是对称矩阵} \\ \frac{\partial f(x)}{\partial a} = 2Xa \end{array} \right)$$

$$\frac{\partial(e'e)}{\partial \hat{\beta}} = -2X'y + 2X'X\hat{\beta}$$

(令其=0 我们)

$$-2X'y + 2X'X\hat{\beta} = 0$$

$$-X'y + X'X\hat{\beta} = 0$$

$$X'X\hat{\beta} = X'y$$

$$\hat{\beta} = (X'X)^{-1}X'y$$

(将  $y = X\beta + \epsilon$  代入)  $\hat{\beta} = (X'X)^{-1}X'(X\beta + \epsilon)$

$$= (X'X)^{-1}X'X\beta + (X'X)^{-1}X'\epsilon$$

$$= \beta + (X'X)^{-1}X'\epsilon$$

$$\begin{aligned}
 (\text{两边互取期望}) \quad E[\hat{\beta}] &= E[\beta + (X'X)^{-1}X'\epsilon] \\
 &= E[\beta] + E[(X'X)^{-1}X'\epsilon] \\
 &= \beta + (X'X)^{-1}X'E[\epsilon] \\
 &= \beta
 \end{aligned}$$

结论：所找寻的预测变量的期望与变量为真实值（无偏 unbiased）

(如果为伪，则期望应为  $\beta + \delta$ ，我们对  $\delta$  不够了解，不足以使用)

### 11) 判断估测的准确性

(预测变量的期望与变量为真值，但实际值未必为真值)

(解答 actual value = true value ?)

$$\begin{aligned}
 \text{Var}(\hat{\beta}) &= E[(\hat{\beta} - E(\hat{\beta}))(\hat{\beta} - E(\hat{\beta}))'] \quad \text{公式: } V(z) = E(z - E(z))^2 \\
 &= E[(\beta + (X'X)^{-1}X'\epsilon - \beta)(\beta + (X'X)^{-1}X'\epsilon - \beta)'] \quad \xrightarrow{\text{代入}} \begin{cases} \hat{\beta} = \beta + (X'X)^{-1}X'\epsilon \\ E[\hat{\beta}] = \beta \end{cases} \\
 &= E[((X'X)^{-1}X'\epsilon)(X'X)^{-1}X'\epsilon')] \\
 &= (X'X)^{-1}X'E[\epsilon\epsilon']X(X'X)^{-1} \\
 &= \sigma^2(X'X)^{-1}X' \mathbb{I}_{p+1} X(X'X)^{-1} \\
 &= \sigma^2(X'X)^{-1}
 \end{aligned}$$

(方差为方差、协方差矩阵；我们没有所需的一切，因此要从数据中估计出  $\sigma^2$ )

(所得出的 OLS 估计量为 BLUE (Best Linear Unbiased Estimator))

(这代表我们可以证明估计量在所有无偏的估计量中是差异最小的)

证明：

$$\hat{\beta} = (X'X)^{-1}X'y$$

$(X'X)^{-1}X'$  是  $(p+1) \times N$  的矩阵，每一个  $p+1$  都为观察值的平均权重

$$\therefore W = (X'X)^{-1}X' + Q \quad \xrightarrow{\text{(非 } (p+1) \times N \text{ 矩阵但占有权重)}}$$

### 12) 估测值的无偏性

$$\text{新预测值: } \tilde{\beta} = Hy \quad \xrightarrow{\text{代入}} \begin{cases} y = X\beta + \epsilon \\ H = ((X'X)^{-1}X' + Q)(X\beta + \epsilon) \end{cases}$$

$$\tilde{\beta} = ((X'X)^{-1}X' + Q)(X\beta + \epsilon)$$

$$\tilde{\beta} = (X'X)^{-1}X'X\beta + QX\beta + (X'X)^{-1}X'\epsilon + Q\epsilon$$

$$\tilde{\beta} = \beta + QX\beta + (X'X)^{-1}X'\epsilon + Q\epsilon$$

要知道  $E[\tilde{\beta}] = \beta$ ，需要  $QX = X'Q' = 0_{(p+1) \times N}$ ，(任何矩阵均满足线性及无偏)

### 13) 估测值的方差

$$\begin{aligned}
 \text{Var}(\tilde{\beta}) &= E[(\tilde{\beta} - E[\tilde{\beta}])(\tilde{\beta} - E[\tilde{\beta}])'] \\
 &= E[(\beta + (X'X)^{-1}X'\epsilon + Q\epsilon - \beta)(\beta + (X'X)^{-1}X'\epsilon + Q\epsilon - \beta)'] \\
 &= E[((X'X)^{-1}X'\epsilon + Q\epsilon)((X'X)^{-1}X'\epsilon + Q\epsilon)'] \\
 &= E[(X'X)^{-1}X'\epsilon\epsilon'X(X'X)^{-1} + (X'X)^{-1}X'\epsilon\epsilon'Q' + Q\epsilon\epsilon'X(X'X)^{-1} + Q\epsilon\epsilon'Q'] \\
 &= \sigma^2((X'X)^{-1} + (X'X)^{-1}X'Q' + Q(X'X)^{-1} + QQ')
 \end{aligned}$$

$$QX = Q'X' = 0_{(p+1) \times N}$$

$$\text{Var}(\tilde{\beta}) = \sigma^2((X'X)^{-1} + QQ') = \text{Var}(\tilde{\beta}) + \sigma^2QQ'$$

:  $QQ'$  的定义为 positive-semi definite matrix

: diagonal elements 是非负的 (non-negative)

新估计量比  $(X'X)^{-1}X'y$  效率低

### 14) 小结:

1. 假设误差期望假设有无偏的
2. 在误差方差一致假设下是有效的
3. 当联合在一起时得出高斯-马尔科夫理论
4. 高斯-马尔科夫理论下说明变量向量  $\beta$  是 BLUE

### 15) Omitted Variable Bias (遗漏变量偏差)

(设定模型时遗漏了相关解释变量 / 忽略了某些对解释变量有直接影响的因素)

总体模型:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + u$$

遗漏  $x_2$ :

$$\tilde{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2$$

$$\sim \sim \sim \sim$$

$$\left\{
 \begin{array}{l}
 \text{如 } y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + u \quad (u \text{ 满足 } E(u)=0) \\
 \text{忽略 } x_2: \quad y = \beta_0' + \beta_1' x_1 + \beta_2' x_2 + u' \\
 \text{误差项: } u' = (\beta_0 - \beta_0') + (\beta_1 - \beta_1') x_1 + (\beta_2 - \beta_2') x_2 + \beta_3 x_3 + u \\
 \text{满足: } E(u') = (\beta_0 - \beta_0') + (\beta_1 - \beta_1') x_1 + (\beta_2 - \beta_2') x_2 + \beta_3 x_3
 \end{array}
 \right.$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2$$

遗漏  $x_2$ :

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1$$

依模型得出解变量关系:

$$x_2 = \hat{\delta}_0 + \hat{\delta}_1 x_1$$

因此:

$$\hat{\beta}_1 = \hat{\beta}_1 + \hat{\beta}_2 \hat{\delta}_1$$

(有偏估计量)

$$E[\hat{\beta}_1] = E[\hat{\beta}_1 + \hat{\beta}_2 \hat{\delta}_1]$$

$$= E[\hat{\beta}_1] + E[\hat{\beta}_2] \hat{\delta}_1 \quad (\text{假设 } \hat{\delta}_1 \text{ 是固定的})$$

$$= \beta_1 + \beta_2 \hat{\delta}_1$$

$$\therefore \text{Bias}(\hat{\beta}_1) = E[\hat{\beta}_1] - \beta_1 = \beta_2 \hat{\delta}_1$$

TABLE 3.2 Summary of Bias in $\hat{\beta}_j$ when $x_j$ Is Omitted in Estimating Equation (3.40)		
	$\text{Corr}(x_i, x_j) > 0$	$\text{Corr}(x_i, x_j) < 0$
$\beta_j > 0$	Positive bias	Negative bias
$\beta_j < 0$	Negative bias	Positive bias

### 16) Multicollinearity (多重共线性)

(当一些解释变量高度相关时)

OLS斜率估计量的样本方差:

$$\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{SST_j(1-R_j^2)}$$

拟合值与残差为同种方法定义的.

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_k x_{ik}$$

$$\hat{\epsilon}_i = y_i - \hat{y}_i$$

残差的样本平均值为0 ( $\bar{\epsilon}_i = \bar{y}_i$ )

$$\sum_{i=1}^n \hat{\epsilon}_i = 0$$

每个解释变量和残差间的样本协方差为0

$$\sum_{i=1}^n \hat{\epsilon}_i x_{ij} = 0 \quad \text{for } j = 1, \dots, k$$

### 17) 拟合程度

$R^2$ : 由所有解释变量解释的y样本变化的分數

$$R^2 \equiv \frac{SSE}{SST} = 1 - \frac{SSR}{SST}$$

(当添加解释变量时,  $R^2$ 总会增加,  $R^2$ 并非比较嵌套模型(nested model)的好工具)

..用调整的  $R^2$  (Adjusted R-squared)

$$\bar{R}^2 \equiv 1 - \frac{\frac{SSR}{n-k-1}}{\frac{SST}{n-1}}$$

## L4 Inference

### 1) 高斯-马尔科夫理论

当MLR.1~MLR.5成立时, OLS估计量  $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k$  是

$\beta_0, \beta_1, \dots, \beta_k$  的最优线性无偏估计量(BLUE)

但为了统计推断, 还需要误差项  $\hat{\epsilon}_i$  的总体布局

(目前以如  $\hat{\epsilon}_i$  的平均值和方差)

MLR.6 总体误差项  $\epsilon_i$  与  $X$  独立, 且与均值为0和方差  $\sigma^2$  服从正态分布

$$\epsilon_i \sim N(0, \sigma^2)$$

(高斯-马尔科夫及正态假设统称为经典线性模型(CLM)假设)

### 2) 样本分布

(在CLM假设下, 并以回归量的样本值为条件)

$$\hat{\beta}_j \sim \text{Normal}(\beta_j, \text{Var}(\hat{\beta}_j))$$

说明:  $\frac{\hat{\beta}_j - \beta_j}{\text{sd}(\hat{\beta}_j)} \sim \text{Normal}(0, 1)$

当将  $\text{sd}(\hat{\beta}_j)$  里的  $\sigma^2$  和  $\text{se}(\hat{\beta}_j)$  里的  $\sigma^2$  替换:

$$\frac{\hat{\beta}_j - \beta_j}{\text{se}(\hat{\beta}_j)} \sim t_{n-k-1} = t_{df}$$

( $k+1$  是总体模型  $y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + u$  中未知参数的个数)

$n-k-1$  是自由度(df)

{ 误差项:  $u' = (\beta_0 - \beta_0') + (\beta_1 - \beta_1') x_1 + (\beta_2 - \beta_2') x_2 + \beta_3 x_3 + u$   
 满足:  $E(u') = (\beta_0 - \beta_0') + (\beta_1 - \beta_1') x_1 + (\beta_2 - \beta_2') x_2 + \beta_3 x_3$   
 因  $x_1, x_2$  和  $x_3$  间无线性关系,  $\beta_0, \beta_1, \beta_2$  和  $\beta_0', \beta_1', \beta_2'$  取任何值,  $E(u')$  不可能都为0, 故必然违反ZCM, 所以OLS估计量常常有偏与非一致性

### 3) 假设检验

如:  $\text{Wage}_i = \beta_0 + \beta_1 \text{female}_i + \beta_2 \text{exper}_i + u_i$

OLS估计:

$$\widehat{\text{Wage}}_i = \widehat{\beta}_0 + \widehat{\beta}_1 \text{female}_i + \widehat{\beta}_2 \text{exper}_i$$

(想测试 experience 对 Wage 有什么影响时, 先控制

其它所有的回归量 (如 female)

做零假设:  $H_0: \beta_2 = 0$

(一旦除  $X_2$  以外的独立变量被计算在内, exper ( $X_2$ ) 对 Wage ( $y$ ) 的期望没有影响)

(不能理解为 exper ( $X_2$ ) 会对 Wage ( $y$ ) 所产生的部分影响, 因为只有当  $\beta_2$  是其它非零值时)

#### t 统计量 (t-statistic)

为了检验零假设:  $H_0: \beta_2 = 0$

$$t = \frac{\widehat{\beta}_2 - \beta_2}{\text{se}(\widehat{\beta}_2)} = \frac{\widehat{\beta}_2 - \beta_2}{\text{se}(\widehat{\beta}_2)}$$

1. t 和  $\widehat{\beta}_2$  同正负

2.  $\widehat{\beta}_2$  越大, t-stat 越大

3. se 越大, t-stat 越小

#### 假设检验: 双边检验

零假设:  $H_0: \beta_2 = 0$  (找证据拒绝零假设)

候选假设:  $H_1: \beta_2 \neq 0$

先明确显著水平 (significant level):  $\alpha$

· 一类误差 (拒绝  $H_0$  为真) 的概率

(通常选取 5%, 不过 1% 或 10% 也很常见)

(为了找临界值 (critical value (c.v.)), 需要当  $H_0$  为真时, 样本的 t 统计分布, t

$$t = \frac{\widehat{\beta}_2 - \beta_2}{\text{se}(\widehat{\beta}_2)} \sim t_{df}$$


(通过统计表找 c.v.)

(为了算 t 统计量, 要从数据中估计出当零假设  $H_0: \beta_2 = 0$  为真时的估量  $\widehat{\beta}_2$ )

$$t = \frac{\widehat{\beta}_2 - 0}{\text{se}(\widehat{\beta}_2)} = [-\text{一个数}]$$

( $t > c.v.$ , 拒绝  $H_0$ )

(c.v. 在自由度为  $n-k-1$  的 t 分布中占 97.5%)



#### 假设检验: 单边检验

候选假设:  $H_1: \beta_2 > 0$

如: OLS 估计量:  $\widehat{\text{Wage}}_i = \widehat{\beta}_0 + \widehat{\beta}_1 \text{female}_i + \widehat{\beta}_2 \text{experience}_i$

(探究女性平均工资是否比男性少 \$2.00)

$$H_0: \beta_2 \geq -2 \quad \text{VS. } H_1: \beta_2 < -2$$

( $\beta_2$  是性别别的参数)

(探究女性平均人数是否少于男性)

$$H_0: \beta_2 \geq 0 \quad \text{VS. } H_1: \beta_2 < 0$$

$$\text{如: } \widehat{\text{Wage}}_i = 9.71 - 2.32 \text{female}_i + 0.08 \text{exper}_i$$

$\text{se}(\widehat{\beta}_2)$  (standard errors)

当  $H_0: \beta_2 \geq -2$  为真, CLM 假设包含

$$\frac{\widehat{\beta}_2 - (-2)}{\text{se}(\widehat{\beta}_2)} \sim t_{df}$$

c.v. = -1.645 (当 Df 为 20 时  $\alpha$  为 0.05, 查表可得)


$$t = \frac{\widehat{\beta}_2 - (-2)}{\text{se}(\widehat{\beta}_2)} = \frac{-2.32 - (-2)}{0.175} = -1.829$$

$-1.829 < c.v. (-1.645)$

(接受零假设, 拒绝候选假设)

结论: 女性平均工资确实比男性少 \$2 (或更多)

{ (实际上, 零假设为  $H_0: \beta_2 \leq 0$ , 但如果我们要证明  
如教育经验, 我们只是关心  $\beta_2$  是非常的小正数)  
教育经验是负的) C 就是当拒绝  $H_0: \beta_2 = 0, \beta_2 < 0$ . 所以  
 $H_0: \beta_2 = 0 \quad \text{VS. } H_1: \beta_2 > 0$ )



统计显著性依靠:  $t$  值  
 经济显著性依靠:  $\hat{\beta}_j$   
 (大的样本量用小的显著性水平(如 1%)  
 小的样本量用大的显著性水平)

(t 表示统计意义要么是 | $t|$  大; 要么  $se(\hat{\beta}_j) \ll$   
 区分 t 统计很重要, 不然导致错误结论(如变量对  
 解释 y 很重要, 虽然其估计影响不大))

#### 4) 区间估计(置信区间)

固定值估计( Point Estimates)和标准差来形成  $(1-\alpha)\%$  区间估计

$$P[-t_{(1-\frac{\alpha}{2}, df)} < t < t_{(1-\frac{\alpha}{2}, df)}] = 1-\alpha$$

(如: 95% 区间,  $B_1, df \rightarrow \infty$ )

$$\hat{\beta}_1 \pm 1.96 \times se(\hat{\beta}_1)$$

$$1.44 \pm 1.96 \times 0.0859$$

(如果分成 100 个区间, 95 个会包括真实参数  $\beta_1$ )

#### 5) P 值

(在 t 统计检验下, 显著性水平最小是 5% 使得我们拒绝零假设)

$$P(|T| > |t|)$$

决定法则:

当 p 值  $< \alpha$ , 拒绝  $H_0$ .

#### 6) 测试单一线性组合

$$\log(\text{donation}) = \beta_0 + \beta_1 \log(\text{tchew}) + \beta_2 \log(\text{trchw}) + \beta_3 \text{sendl} + \beta_4 \text{eduhd} + \beta_5 \text{eduwf} + u$$

(探究户主和妻子的教育程度是否对慈善捐款有着一致的影响)

$$H_0: \beta_4 = \beta_5$$

测试统计量:

$$t = \frac{\hat{\beta}_4 - \hat{\beta}_5}{se(\hat{\beta}_4 - \hat{\beta}_5)}$$

$$\text{当: } se(\hat{\beta}_4 - \hat{\beta}_5) = \sqrt{\text{Var}(\hat{\beta}_4) + \text{Var}(\hat{\beta}_5) - 2\text{cov}(\hat{\beta}_4, \hat{\beta}_5)}$$

(将问题重新参数化), 令  $\theta = \hat{\beta}_4 - \hat{\beta}_5$ , 则  $H_0: \theta = 0$

$$H_0: \theta = 0 \quad \text{vs.} \quad H_1: \theta < 0$$

$$\begin{aligned} \therefore \log(\text{donation}) &= \beta_0 + \beta_1 \log(\text{tchew}) + \beta_2 \log(\text{trchw}) + \beta_3 \text{sendl} + (\theta + \beta_5) \text{eduhd} + \beta_5 \text{eduwf} + u \\ &= \beta_0 + \beta_1 \log(\text{tchew}) + \beta_2 \log(\text{trchw}) + \beta_3 \text{sendl} + \theta \text{eduhd} + \beta_5 \text{eduwf} + u \end{aligned}$$

(将新变量  $\text{eduhd} + \text{eduwf}$  取代  $\text{eduhd}$ , 来估测  $\theta$  和观测标准差  $\hat{\theta}$ )

$$\text{令 } \text{totedu} = \text{eduhd} + \text{eduwf}$$

$$\log(\text{donation}) = \beta_0 + \beta_1 \log(\text{tchew}) + \beta_2 \log(\text{trchw}) + \beta_3 \text{sendl} + \theta \text{totedu} + \beta_5 \text{eduwf} + u$$

(这样使当估计新模型时,  $\text{eduhd}$  上的系数为  $\theta$ , 且  $se(\hat{\theta})$  一同被估计)

#### 7) Testing Multiple Linear Restrictions (F 统计模型)

计量模型如:

$$\log(\text{donation}) = \beta_0 + \beta_1 \log(\text{tchew}) + \beta_2 \log(\text{trchw}) + \beta_3 \text{sendl} + \beta_4 \text{eduhd} + \beta_5 \text{eduwf} + u$$

慈善捐款 ↑      应纳税额收入 ↑      其他转移收入 ↑      户主性别 ↑      P 主教育水平 ↑      妻子教育水平 ↑

(探究一旦控制了收入, 那么教育和性别对捐款没有影响)

零假设:

$$H_0: \beta_4 = \beta_5 = 0$$

候选假设:

$$H_1: \beta_k \neq 0 \quad \text{for } k = 3, 4, 5$$

在零假设中用制约因素:

$$\log(\text{donation}) = \beta_0 + \beta_1 \log(\text{tchew}) + \beta_2 \log(\text{trchw}) + u$$

(比较有限制后和无限制模型)

$$F = \frac{\frac{SSR_r - SSR_u}{k}}{\frac{SSR_u}{df_u}}$$

(两个模型中都用 SSR)  
 (受限制的个数)

(无制约模型的 SSR; 自由度)

$$F = \frac{\frac{(R_{\text{u}}^2 - R_r^2)}{k}}{\frac{(1 - R_{\text{u}}^2)}{df_u}}$$

在零假设, CLM 假设成立情况下, F 统计量是有着 f-df 的 F 分布

dfn

在零假设，CLM假设成立情况下，F统计量是有着 $f_{df_n}$ 的F分布

$$F \sim F_{q, df_n}$$


(假设步驟与 t 测試时一致)

1. 零假设和备选假设

2. 测試统计量 (在零假设下的分布)

3. 显著性水平和临界值 (从统计表中查)

4. 推演和结论



(模型中所有的斜率参数为0)

$$H_0: \beta_1 = \beta_2 = \dots = \beta_K = 0$$

限制后的模型为：

$$y = \beta_0 + u$$

F 统计量：

$$F = \frac{\frac{R^2}{K}}{\frac{(1-R^2)^2}{(n-K-1)}}$$

(通常被称为回归总显著性并包含于任何的回归结果中)

## L5 方程形式


### 1) 对数

TABLE 2.3 Summary of Functional Forms Involving Logarithms			
Model	Dependent Variable	Independent Variable	Interpretation of $\beta_1$
Level-level	y	x	$\Delta y = \beta_1 \Delta x$
Level-log	y	log(x)	$\Delta y = \beta_1 (\Delta \log x)$
Log-level	log(y)	x	$\Delta \log y = (\beta_1 \Delta x)$
Log-log	log(y)	log(x)	$\Delta \log y = \beta_1 \Delta \log x$

(半弹性演绎 (semi-elasticity interpretation) 只在小百分比数值中有效  
但仍可以让 CLM 假设更真实)

正态假设

$$CLM \text{ 假设} \Rightarrow y|x \sim N(\beta_0 + \beta_1 x, \sigma^2)$$



- 当有正的货币性数值时 (wage, firm sales, house prices...) 使用对数
- 变量为时间性的 (education, experience, age...) 时通常不用
- 注意使用百分比的数据报告 (interest rates, unemployment rates...)

### 2) $\widehat{\log(y)}$ 中 y 的预测

如：

$$\log(y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_K x_K + u$$

由此得出  $\widehat{\log(y)}$  预测为：

$$\widehat{\log(y)} = \widehat{\beta}_0 + \widehat{\beta}_1 x_1 + \widehat{\beta}_2 x_2 + \dots + \widehat{\beta}_K x_K$$

y 的朴素预测：

$$\widehat{y} = \exp(\widehat{\beta}_0 + \widehat{\beta}_1 x_1 + \widehat{\beta}_2 x_2 + \dots + \widehat{\beta}_K x_K)$$

但在 CLM 假设下：

$$\widehat{y} = \exp\left(\frac{\widehat{\beta}_1}{2}\right) \exp(\widehat{\log(y)})$$

### 3) 二次型 (Quadratic)

如：Wage<sub>i</sub> =  $\beta_0 + \beta_1 \text{experience}_i + u_i$

(Quadratic form 可以使 experience 具有收益递减性)

Quadratic form :


$$\widehat{\text{Wage}} = \widehat{\beta}_0 + \widehat{\beta}_1 \text{exper} + \widehat{\beta}_2 \text{exper}^2$$

$$\text{推演: } \frac{\Delta \text{Wage}}{\Delta \text{exper}} = (2\widehat{\beta}_2 + 2\widehat{\beta}_1 \text{exper})$$


如果  $\widehat{\beta}_2 > 0$ , U 的抛物线

如果  $\widehat{\beta}_2 < 0$ , Η 的抛物线

$$\text{如: } \widehat{\text{Wage}} = 6.477 + 0.302 \text{ exper} - 0.006 \cdot 3 \text{ exper}^2$$



如果  $\beta_2 > 0$ , U 的抛物线  
如果  $\beta_2 < 0$ , N 的抛物线



$$\hat{y}_0: \hat{\text{wage}} = 6.477 + 0.302 \text{ exper} - 0.006 \cdot 3 \text{ exper}^2$$

$$1^{\text{st}}, (\text{exper} = 0) \quad 0.302 - 2 \times 0.006 \cdot 3 \times 0 = \$0.302/\text{h}$$

$$2^{\text{nd}}, (\text{exper} = 1) \quad 0.302 - 2 \times 0.006 \cdot 3 \times 1 = \$0.29/\text{h}$$

$$\begin{cases} \hat{\beta}_1 + 2\hat{\beta}_2 \text{ exper} \\ \hat{\beta}_1 = 0.302; \hat{\beta}_2 = -0.006 \cdot 3 \end{cases}$$

#### 4) 虚拟变量

变量如  $\text{educ}$  和  $\text{exper}$  是有量化 (Quantitative) 意义的 (数的大小都有信息)

经验中还有些起重要作用的定性 (Qualitative) 因素

如：性别、(有无) 宗教信仰等 (通常是二元答案 (如有或无))

可以用 1 或 0 分别代表


如:  $\text{female} = 1$  为女性;  $\text{female} = 0$  为男性

$$a) \hat{\text{wage}} = \hat{\beta}_0 + \hat{\beta}_1 \text{female} + \hat{\beta}_2 \text{educ}$$

推演  $\hat{\beta}_0$ : (假设 ZCM 假设成立 ( $E[u|\text{female}, \text{educ}] = 0$ )

$$\hat{\beta}_0 = E[\text{wage} | \text{female} = 1, \text{educ}] - E[\text{wage} | \text{female} = 0, \text{educ}]$$


(使用虚拟变量使交点位移)



$$b) \hat{\text{wage}} = \hat{\beta}_0 + \hat{\beta}_1 \text{female} + \hat{\beta}_2 \text{educ} + \hat{\beta}_3 \text{female} \times \text{educ}$$

当  $\hat{\beta}_3$  为男或女时会导致交点位移

当  $\hat{\beta}_3$  为男或女时会导致斜率不同



$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_1 x_2$$

$$\frac{\Delta \hat{y}}{\Delta x_1} = \hat{\beta}_1 + \hat{\beta}_3 x_2$$

当  $x_2 = 0$  时,  $\hat{\beta}_1$  是与  $\Delta x_1$  关联的  $\Delta \hat{y}$

如:  $\hat{\beta}_3 > 0$ : 当  $x_2$  为 1 时,  $x_1$  增加对  $\hat{y}$  增加的影响大于  $x_2$  为 0 时的  $x_1$  增加

$\hat{\beta}_3 < 0$ : 当  $x_2$  为 1 时,  $x_1$  增加对  $\hat{y}$  增加的影响小于  $x_2$  为 0 时的  $x_1$  增加

进行 t 检测:  $H_0: \delta_1 = 0$

(检测同性别下教育的回报是否相同)

(如斜率的不同)

进行 F 检测:  $H_0: \delta_0 = \delta_1 = 0$

(如性别是否对工资有任何影响)

(将斜率和交点合平检验)

$$\text{Wage} = \beta_0 + \delta_0 \text{female} + \beta_1 \text{married} + \delta_2 \text{female} \times \text{married} + u$$

· 当  $\text{female} = 0 \& \text{married} = 0 \Rightarrow$  单身男性 ( $\beta_0$ )

· 当  $\text{female} = 0 \& \text{married} = 1 \Rightarrow$  已婚男性 ( $\beta_0 + \delta_1$ )

· 当  $\text{female} = 1 \& \text{married} = 0 \Rightarrow$  单身女性 ( $\beta_0 + \delta_2$ )

· 当  $\text{female} = 1 \& \text{married} = 1 \Rightarrow$  已婚女性 ( $\beta_0 + \delta_0 + \delta_1 + \delta_2$ )

#### 5) 分类变量

可取多种值的定性因素

如: 学位类型: 信仰

1 = 一等 1 = 佛教

2 = 二等 2 = 基督教

3 = 二等二 3 = 伊斯兰教

(顺序无所谓; 需要转化为多个虚拟变量)

一些分类变量有着自然顺序

如: 学位类型; 学位等级

1 = GCSE

2 = A-Level

~ ~

1 = GCSE

2 = A-Level

3 = BSc

4 = MSc

5 = PhD

$$\text{Wage} = \beta_0 + \beta_1 \text{degree} + u$$

(或看用虚拟变量列出每一个)

$$\text{Wage} = \delta_0 + \delta_1 d_1 + \delta_2 d_2 + \dots + \delta_5 d_5 + u$$

## L6 一致性和内生性

### 1) 内生性的由来

ZCM 假设

$$E[u|x_1, x_2, \dots, x_n] = 0$$

然而, 当:

$$E[u|x_i] \neq 0$$

我们称  $x_i$  是内生性解释变量

内生性的来源

{  
遗漏变量  
同步性  
误差测量


{ 内生性: 模型中一个或多个解释变量与随机扰动相关  
思路: 比较 OLS 与 IV 估计量, 若都是外生的, 则 OLS 与 IV 一致; 不同则为解释变量有内生性

如:  $y_i = \alpha + \beta x_i + u_i$

变化  $x_i$  会导数  $\beta$  改变  $y$

以上三种均导致  $x_i$  是有内生性

Causal Paths



### 2) 一致性

在高斯-马尔科夫假设下 OLS 是 BLUE (最优线性无偏估计量)

但如果高-马假设不成立, 则没有具有无偏估计量的可能性


在这种情况下, 我们便能满足一致的估计量

(估计量的分布折叠为  $\pi \rightarrow 0$  的真实值, 则估计量是一致的)

(具有一致性是估计量的最低要求)

· 高-马假设下 OLS 估计量是一致的 (且无偏)

如果  $\text{plim}(\hat{\beta}_j) = \beta_j$ , 则  $\hat{\beta}_j$  是  $\beta_j$  的一致估计量  
(概率极限)



{ 全  $\hat{\beta}_j$  是  $\beta_j$  的 OLS 估计量, 依高-马 MLR.1 ~ 4,  
 $\hat{\beta}_j$  是无偏的, 该分布有均值  $\beta_j$ . 如果估计量是一致的,  
该的分布将随着  $\beta_j$  的增加而愈发分布在  $\beta_j$  周围, 当  $n$  取无限时,  $\hat{\beta}_j$  将会折叠到  $\beta_j$  点上.

· 对于无偏性, 假设 ZCM (零条件均值)

$$E[u|x_1, \dots, x_k] = 0$$

· 对于一致性, 应用平均值和协方差为 0 这更少限制的假设

$$E[u] = 0 \ \& \ \text{cov}(x_j, u) = 0 \text{ for } j=1, \dots, k$$

(如果都不满足, OLS 有偏且不一致)

### 3) 测量误差 (Chapter 9)

如:  $y^* = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + u$

但观测  $y$  而非  $y^*$

测量误差:  $e_i = y - y^*$

$$\therefore y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + (u + e_i)$$

假定  $e_i$  与  $x_i$  无关, 则 OLS 是无偏的

如:  $y = \beta_0 + \beta_1 x_1^* + u$

(满足 MLR.1 ~ 4) 但观测  $x_1$  而非  $x_1^*$

令  $x_1 = x_1^* + e_1$ , 当  $E[e_1] = 0$  (均值为 0)

{ 因为假设  $u$  和  $e_i$  均值为 0 且与  $x_i$  无关;  
 $u - \beta_1 e_i$  均值为 0 且与  $x_i$  无关, 那么  $x_i$  取代  $x_i^*$   
对于 OLS 估计时会产生一致的估计量  $\hat{\beta}_1$  (和  $\hat{\beta}_0$ )  
因  $u$  和  $e_i$  无关, 误差的方差是  $\text{Var}(u - \beta_1 e_i)$   
 $= \sigma_u^2 + \beta_1^2 \sigma_{e_i}^2$ . 故当  $R=0$ , 测量误差增大了误差

如:  $y = \beta_0 + \beta_1 x_i^* + u$   
 (满足 MLR.1 ~ 4) 但观测  $x_i$  而非  $x_i^*$   
 令  $x_i = x_i^* + e_i$ , 当  $E[e_i] = 0$  (均值为 0)  
 则:  $y = \beta_0 + \beta_1 x_i + (u - \beta_1 e_i)$

方程 OLS 估计时会产生一致的估测量  $\hat{\beta}_1$  和  $\hat{\beta}_0$   
 因  $u$  和  $e_i$  无关, 误差的方差是  $\text{Var}(u - \beta_1 e_i)$   
 $= \sigma_u^2 + \beta_1^2 \sigma_{e_i}^2$ . 故当  $\beta_1 = 0$ , 测量误差增大了误差  
 方差, 但对 OLS 的性质无影响

### 经典误差值假设 (Classical errors-variables (CES))

$$\text{Cov}(x_i^*, e_i) = 0$$

当满足 CES 时,  $x_i$  和  $e_i$  必有以下关系

$$\text{cov}(x_i, e_i) = E[x_i e_i] = E[x_i^* e_i] + E[e_i^2] = 0 + \sigma_{e_i}^2$$

用在估测模型

$$y = \beta_0 + \beta_1 x_i + (u - \beta_1 e_i)$$

$x_i$  与复合误差  $u - \beta_1 e_i$  有关:

$$\text{cov}(x_i, u - \beta_1 e_i) = -\beta_1 \text{Cov}(x_i, e_i) = -\beta_1 \sigma_{e_i}^2$$

OLS 的有偏和不一致的量: (当  $\text{Var}(x_i) = \text{Var}(x_i^*) + \text{Var}(e_i)$ )

$$\text{plim}(\hat{\beta}_1) = \beta_1 + \frac{\text{Cov}(x_i, u - \beta_1 e_i)}{\text{Var}(x_i)}$$

$$= \beta_1 - \frac{\beta_1 \sigma_{e_i}^2}{\sigma_{x_i^*}^2 + \sigma_{e_i}^2}$$

$$= \beta_1 \left( 1 - \frac{\sigma_{e_i}^2}{\sigma_{x_i^*}^2 + \sigma_{e_i}^2} \right)$$

$$= \beta_1 \left( \frac{\sigma_{e_i}^2}{\sigma_{x_i^*}^2 + \sigma_{e_i}^2} \right)$$

•  $\beta_1$  的乘积, 即  $\frac{\text{Var}(x_i^*)}{\text{Var}(x_i)}$  的比例总是小于 1,  
 因为  $\text{Cov}(x_i^*, e_i) = 0$ . 因此,  $\text{plim}(\hat{\beta}_1)$  总是比  
 $\beta_1$  更靠近 0 (OLS 偏的衰减)

### 4) 联立方程模型 (simultaneous equation model)

如:

$$\text{crime} = \alpha_1 \text{police} + \beta_1 \text{aunginc} + u_1 \quad ①$$

$$\text{police} = \alpha_2 \text{crime} + \beta_2 \text{tax} + u_2 \quad ②$$

$$\text{将 } ② \text{ 代入 } ①: \text{crime} = \alpha_1 (\alpha_2 \text{crime} + \beta_2 \text{tax} + u_2) + \beta_1 \text{aunginc} + u_1.$$

$$\text{重新组合: } (1 - \alpha_1 \alpha_2) \text{crime} = \alpha_1 \beta_2 \text{tax} + \beta_1 \text{aunginc} + \alpha_1 u_2 + u_1$$

$$\text{crime} = \frac{\alpha_1 \beta_2}{1 - \alpha_1 \alpha_2} \text{tax} + \frac{\beta_1}{1 - \alpha_1 \alpha_2} \text{aunginc} + \frac{\alpha_1 u_2 + u_1}{1 - \alpha_1 \alpha_2}$$

### L7 工具变量 (Instrumental Variables) (Chapter 15)

#### 1) OLS 的渐近性 (Asymptotic)

(描述  $n \rightarrow \infty$  的大型样本中的估计量的性质)

1. 无偏:

$$E[\hat{\beta}] = \beta, \text{ 估计量 } \hat{\beta} \text{ 的性质}$$

(意为估计量的样本分布与真实值相等)

2. 一致:

当样本量扩大, 估计量的覆盖率达到真实的总值

(意为当样本量扩大时 估计量的样本方差怎样变的问题)

#### 2) 工具变量

$$\text{如: } \text{Wage}_i = \beta_0 + \beta_1 \text{educ}_i + \beta_2 \text{ability}_i + u_i$$

但  $\text{ability}$  不可测量

$$\therefore \text{Wage}_i = \beta_0 + \beta_1 \text{educ}_i + u_i$$

如果  $\text{educ}$  和  $\text{ability}$  是有相关性的, 那  $E[u|x] \neq 0; \text{cov}(x, u) \neq 0$

$\Rightarrow$  OLS 既有偏又不一致

且  $\hat{\beta}_1$  不再能因果推演 (causal interpretation)

$$y = \beta_0 + \beta_1 x + u$$

$\text{1. } \text{Cov}(x, u) \neq 0$

假设有观测值  $z$ , 且满足:

1)  $\text{Cov}(z, u) = 0$

2)  $\text{Cov}(z, x) \neq 0$


$z$  便是工具变量

1) 为工具外生性

2) 为工具相关

3)  $z$  不应包括在模型中

## Causal Paths



(为了估测设定所需的因果关系,  $x$  对  $y$  有影响,  
但只在内生性变量  $x$  下有影响)

### 工具变量的估测量

在  $E[u|x] \neq 0$  下:

$$y = \beta_0 + \beta_1 x + u$$

一: 假设  $\text{cov}(z, x) \neq 0$

$$x = \pi_0 + \pi_1 z + v$$


$$\frac{\Delta x}{\Delta z} = \pi_1$$

$$\begin{aligned} \text{二: } y &= \beta_0 + \beta_1 [\pi_0 + \pi_1 z + v] + u \\ &= [\beta_0 + \beta_1 \pi_0] + \beta_1 \pi_1 z + [\beta_1 v + u] \end{aligned}$$

$$\frac{\Delta y}{\Delta z} = \beta_1 \pi_1$$

$$\text{故: } \frac{\Delta y}{\Delta x} = \frac{\frac{\Delta y}{\Delta z}}{\frac{\Delta x}{\Delta z}} = \frac{\beta_1 \pi_1}{\pi_1} = \beta_1$$

假设:  $\text{cov}(z, x) \neq 0$  且  $\text{cov}(z, u) = 0$



估测步骤一:

$$\hat{x} = \hat{\pi}_0 + \hat{\pi}_1 z$$

将拟合值代入二:

$$\begin{aligned} y &= \beta_0 + \beta_1 [\pi_0 + \pi_1 z + v] + u \\ &= \beta_0 + \beta_1 \hat{x} + u \end{aligned}$$

用  $\text{cov}(z, x) \neq 0$  和  $\text{cov}(z, u) = 0$  来确认  $\beta_1$ .

Identification of  $\beta_1$ : 把  $\beta_1$  写成可被样本数据估测的总体矩阵条件 (Population moment condition)

用  $y = \beta_0 + \beta_1 x + u$  去获得  $x$  和  $y$  的协方差

$$\text{cov}(z, y) = \beta_1 \text{cov}(z, x) + \text{cov}(z, u)$$

$$\text{重新排列: } \beta_1 = \frac{\text{cov}(z, y)}{\text{cov}(z, x)}$$

$$\text{样本副本: } \hat{\beta}_1 = \frac{\sum_{i=1}^n (z_i - \bar{z})(y_i - \bar{y})}{\sum_{i=1}^n (z_i - \bar{z})(x_i - \bar{x})}$$

二 工具变量 (IV) 的估计量:

$$\hat{\beta}_1^{IV} = \frac{\sum_{i=1}^n (z_i - \bar{z})(y_i - \bar{y})}{\sum_{i=1}^n (z_i - \bar{z})(x_i - \bar{x})} \quad \& \quad \hat{\beta}_0^{IV} = \bar{y} - \hat{\beta}_1^{IV} \bar{x}$$

(一致但有偏) 因此 IV 估计量只用于判断‘大’变量

当  $z = x$  时, (如  $x$  是实际外生且可被认为自身的工具)  
则  $\hat{\beta}_1^{IV} = \hat{\beta}_1^{OLS}$  (比较 OLS 与 IV 的估计量)

好的工具变量的来源:

1. 相关性  $\text{cov}(z, x) \neq 0$

2. 外生性  $\text{cov}(z, x) = 0$

3.  $z$  不应包含在模型中

好的 IV 难以找寻:

如: 自然灾害, 政策变化

## 面板数据方法估计量 (Panel Data Methods Estimators)

1) 部氏检验 (CHOW test) (F 检测)

| 面板数据 (Cross Section Data)

(进行跨单元观测，以查看它们的差异)

独立面板样本

如:  $\log(\text{wage})_{it} = \beta_0 + \delta_i \text{wave2}_{it} + \beta_1 \text{educ}_{it} + \beta_2 \text{exper}_{it} + \beta_3 \text{female}_{it} + \beta_4 \text{female}_{it} \text{wave2}_{it} + \epsilon_{it}$ 

(i 指代人; t 为时间段; wave2 指观测指标 2 阶段; 随时间的推移, 性别工资差距)

(使用部氏检测 (主要为两个时间段的 F 检测); 虚拟变量的另一应用便是发现时间授下的模型差异)

如:  $g = 1, 2$  两个组下的模型

$$y = \beta_{0,g} + \beta_{1,g}x_1 + \dots + \beta_{p,g}x_p + \epsilon$$

一:  $\beta_{1,g}$  为每一组下的参数; 因此可用联合假设 (joint hypotheses)

$$H_0: \beta_{1,1} = \beta_{1,2} \quad \forall i$$

(空称量词, 对所有的 i; 每一个 i)

(应用 F 检测, 其两组中所有参数的受限模型相等)

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p + \epsilon$$

如:  $\log(\text{wage})_{it} = \beta_0 + \delta_i \text{wave2}_{it} + \beta_1 \text{educ}_{it} + \beta_2 \text{exper}_{it} + \beta_3 \text{female}_{it} + \beta_4 \text{female}_{it} \text{wave2}_{it} + \alpha_i + \epsilon_{it} \leftarrow$ (  $\alpha_i$  是随时间推移而不变的所有未被观测的异质性) (如与 x 的差异有关, 则有因遗漏恒定变量时间造成的有偏)二: ..要移出异致性偏差 (虚拟变量需要照顾每一年 ( $R^2$  同理会更高) 因此不好)